Etapa 1 – Exploração do Dataset

1.1 Dimensões e Tipos de Variáveis

O dataset possui 86 linhas (alunos) e 7 colunas. As variáveis se dividem em dois tipos:

Variável	Tipo	Descrição
nome_aluno	Categórica (texto)	Nome completo do aluno
matricula	Numérica (inteiro)	Código de matrícula do aluno
email	Categórica (texto)	Endereço de e-mail do aluno
horas_estudo	Numérica (inteiro)	Horas de estudo por semana
aulas_assistidas	Numérica (inteiro)	Quantidade de aulas assistidas
faltas	Numérica (inteiro)	Número de faltas no período
nota_final	Numérica (inteiro)	Nota final do aluno (variável-alvo)

1.2 Estatísticas da Nota Final

Medida	Valor
Média	73,67
Mediana	74,50
Moda	79
Q1 (25%)	63,00
Q2 / Mediana (50%)	74,50
Q3 (75%)	85,00
Desvio Padrão (amostral)	13,95
Mínimo / Máximo	45 / 98

1.3 Interpretação

A nota final apresenta média (73,67) e mediana (74,50) muito próximas, o que indica uma distribuição aproximadamente simétrica — sem grande distorção causada por valores extremos. A moda é 79, ligeiramente acima da mediana, sugerindo que essa faixa de notas é a mais frequente no dataset.

O intervalo interquartil (IQR = Q3 − Q1 = 85 − 63 = 22 pontos) indica que metade dos alunos se concentra entre 63 e 85 pontos. Com desvio padrão de ≈ 13,95, a maioria dos alunos se encontra entre ~60 e ~87 pontos, evidenciando uma dispersão moderada mas consistente.

A comparação entre Excel e Python confirmou resultados idênticos para todas as métricas calculadas, validando a consistência das ferramentas.

Etapa 2 – Estatística Descritiva com NumPy

2.1 Resultados Obtidos

Métrica	NumPy	Excel	Iguais?
Média	73,6744	73,67	✓
Mediana	74,5000	74,50	✓
Desvio Padrão	13,9473	13,95	✓
Q1 (25%)	63,0000	63,00	✓
Q2 (50%)	74,5000	74,50	✓
Q3 (75%)	85,0000	85,00	✓

2.2 Interpretação

Os resultados obtidos com NumPy são idênticos aos calculados no Excel, confirmando a consistência entre as ferramentas. O parâmetro ddof=1 foi utilizado no np.std() para calcular o desvio padrão amostral — adequado quando trabalhamos com uma amostra da população, e não com a população inteira.

O desvio padrão de ≈ 13,95 indica uma dispersão moderada em torno da média. Em termos práticos, a maioria dos alunos obteve notas entre aproximadamente 60 e 87 pontos, o que é coerente com o intervalo interquartil (Q1=63, Q3=85).

A proximidade entre média (73,67) e mediana (74,50) confirma a simetria da distribuição, sem forte influência de outliers. Isso significa que não há um grupo pequeno de alunos puxando a média significativamente para cima ou para baixo.

Etapa 3 – Análise de Correlação

3.1 Resultados

Par de Variáveis	Correlação (r)	Classificação
horas_estudo × nota_final	0,9966	Muito forte positiva
aulas_assistidas × nota_final	0,9947	Muito forte positiva
faltas × nota_final	−0,9781	Muito forte negativa

3.2 Interpretação

Horas de estudo × Nota final (r = 0,997): existe uma relação quase linear entre o tempo de estudo semanal e a nota final. A cada hora adicional de estudo, a nota tende a aumentar de forma muito consistente. Trata-se de uma das correlações mais fortes que se pode encontrar em dados reais.

Aulas assistidas × Nota final (r = 0,995): a frequência nas aulas tem impacto igualmente forte sobre o desempenho. Alunos mais presentes tendem fortemente a obter notas mais altas, o que faz sentido intuitivo no contexto educacional.

Faltas × Nota final (r = −0,978): a correlação negativa muito forte confirma que quanto mais faltas, menor a nota. Essa relação é inversa e quase tão intensa quanto as anteriores.

Nota importante sobre Correlação e Causalidade:
Correlação não implica causalidade. Embora as correlações acima sejam altíssimas e façam sentido intuitivo, não podemos afirmar com certeza que estudar mais CAUSA notas maiores apenas com base na correlação — podem existir variáveis de confusão (ex.: motivação do aluno). No entanto, no contexto educacional, essas relações são esperadas e empiricamente bem fundamentadas.

Etapa 4 – Teste de Hipótese: Seleção de Amostras

4.1 Hipótese

Hipótese:
Alunos que estudam mais de 10 horas por semana têm nota média maior do que alunos que estudam até 10 horas por semana.

4.2 Grupos Formados

Métrica	Grupo ≤ 10h/semana	Grupo > 10h/semana	Diferença
Tamanho (n)	28 alunos	58 alunos	–
Nota Média	57,18	81,64	24,46
Nota Mínima	45	60	–
Nota Máxima	73	98	–

4.3 Justificativa da Escolha Amostral

Tipo de Teste: Amostras Independentes

A divisão foi feita em dois grupos mutuamente exclusivos com base na variável horas_estudo, usando o critério de corte proposto no enunciado (10 horas). Cada aluno pertence a exatamente um grupo, sem sobreposição — isso caracteriza amostras independentes (não pareadas).

Teste Estatístico Recomendado

O teste mais adequado para comparar as médias de dois grupos independentes é o Teste t de Student para amostras independentes (two-sample t-test). Suas condições de aplicação são:

- Os grupos são independentes entre si.
- A variável de interesse (nota_final) é numérica contínua.
- Assume-se distribuição aproximadamente normal em cada grupo (verificável com teste de normalidade, como Shapiro-Wilk).

Caso a normalidade não seja garantida, utiliza-se o teste não-paramétrico de Mann-Whitney U como alternativa, que compara as distribuições sem assumir normalidade.

Conclusão Preliminar

A diferença de 24,46 pontos entre as médias dos grupos (57,18 vs 81,64) é expressiva e sugere fortemente que a hipótese é verdadeira. Um teste t formal com nível de significância $\alpha = 0{,}05$ confirmaria se essa diferença é estatisticamente significativa — ou seja, se é improvável de ter ocorrido por acaso.

Etapa 5 – Regressão Linear

5.1 Resultados do Modelo

Métrica	Valor
MSE	0,3394
MAE	0,4217
R^2 Score	0,9982